UNIVERSITÉ DE SHERBROOKE · ÉCOLE DE GESTION

GIS805

Session 01 / 14

NexaMart kickoff : pourquoi l'organisation ne peut pas répondre à ses propres questions

Structuration et analyse multidimensionnelle

C

PROFESSEUR

Prof. Carlos Denner dos Santos

Département des systèmes d'information et méthodes quantit...

DATE

4 mai 2026

LIEU

Longueuil

HORAIRE

19 h 00 – 22 h 00

Sondage d'ouverture

PROFOS

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

En un mot : qu'est-ce qu'un entrepôt de données ?

https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GIS805-01/poll/opening-poll

Votre séance, en bref

Voici comment se déroule votre soirée — 5 temps forts.

- **10 min** Arrivee + CEO brief + Wooclap
- **20 min** Concepts + simulation NexaMart
- **20 min** Onboarding sprint
- **25 min** Exploration diagnostique + debrief concepts
- **45 min** Premier board brief + demos

Quelles catégories de produits déclinent, dans quelles régions, et pourquoi ?

— Le CEO de NexaMart Group, aujourd'hui

Pourquoi cette question est-elle si difficile ?

Les données existent. La reponse, non.

- Le système de ventes enregistre chaque transaction
- Le système d''inventaire suit chaque produit
- Le CRM connait chaque client
- Pourtant, personne ne peut répondre au CEO ce soir
- Ce cours existe parce que ce problème est universel

05

Le diagnostic fondamental

Pourquoi les systèmes d'entreprise ne répondent pas aux questions stratégiques

OLTP : Online Transaction Processing

Les systèmes qui font tourner l''entreprise

- **Mission :** enregistrer chaque événement (vente, commande, retour, paiement)
- Optimise pour la vitesse d'ecriture -- une transaction à la fois
- Structure normalisee (3NF) -- chaque donnée a un seul endroit
- **Exemples chez NexaMart :** SAP (ERP), Salesforce (CRM), Oracle POS

Analogie : un carnet de caisse. Parfait pour noter, impossible pour analyser.

OLAP : Online Analytical Processing

Les systèmes qui eclairent les décisions

- **Mission :** répondre a dès questions stratégiques rapidement
- Optimise pour la vitesse de lecture -- scanner des millions de lignes
- Structure denormalisee (star schema) -- redondance voulue pour la lisibilite
- **Exemples :** Snowflake, BigQuery, Amazon Redshift, DuckDB

Analogie : un tableau de bord. Construit a partir du carnet, mais structure differemment.

OLTP vs OLAP : côte à côte

OLTP

- But : enregistrer
- Optimise : ecriture
- Structure : normalisee (3NF)
- Utilisateurs : employes, systèmes
- Données : ligne par ligne
- Question : "Combien de X ce matin ?"

OLAP

- But : analyser
- Optimise : lecture
- Structure : denormalisee (star)
- Utilisateurs : analystes, dirigeants
- Données : agrégées par dimension
- Question : "Quelle tendance par région ?"

La pensee multidimensionnelle

Le cadre conceptuel du cours

- **MESURE -- ce qu'on compte :** revenue, quantite vendue, marge, nombre de retours
- **DIMENSION -- l'axe d'analyse :** produit (quoi), client (qui), date (quand), magasin (ou)
- **HIÉRARCHIE -- le zoom :** année > trimestre > mois > semaine > jour
- **GRAIN -- le niveau de detail :** une ligne = une vente, un jour, un produit ?

La question du CEO, décomposée

Quelles catégories déclinent, dans quelles régions, et pourquoi ?

- **Mesure :** revenue (et son évolution dans le temps)
- **Dimension 1 :** catégorie de produit (Electronics, Home, Clothing, Food)
- **Dimension 2 :** région géographique (Quebec, Ontario, BC, Alberta)
- **Dimension 3 :** temps (par trimestre, pour voir la tendance)
- = Un cube a 3 axes. L'entrepôt de données construit ce cube.

Pourquoi un ERP ne peut pas construire ce cube

Le problème structurel

- Les ventes sont dans une table, les produits dans une autre, les magasins dans une troisieme
- Les catégories ne sont pas standardisees entre systèmes
- Les dates sont des timestamps, pas des periodes analytiques
- Chaque requête nécessite 5+ jointures complexes et des règles de transformation
- **Resultat :** chaque analyste produit un chiffre différent pour la même question

C'est le problème que Ralph Kimball a resolu avec le schema en étoile -- on y arrive en S02.

Deux misconceptions courantes

"LES DONNÉES SONT LA, ON N'A QU'A DEMANDER"

- Les données EXISTENT, oui
- Mais elles sont structurées pour enregistrer, pas pour analyser
- Joindre 5 tables avec des règles temporelles = fragile et non reproductible
- Un rapport qui prend 3 jours a produire n'est pas un actif stratégique

"UN BON ANALYSTE EXCEL PEUT LE FAIRE"

- Un analyste peut répondre UNE fois a UNE question
- La prochaine question nécessite de tout refaire
- Pas auditable, pas reproductible, pas partageable
- L'entrepôt rend la reponse repetable, fiable, et automatisable

13

Bienvenue chez NexaMart Group

Votre entreprise pour les 14 prochaines semaines

Le boardroom model

Ce n'est pas un cours avec des exercices -- c'est une simulation

- Le CEO (votre instructeur) pose une question stratégique chaque semaine
- Vous etes le Head of Data -- vous construisez la reponse
- Votre dépôt Git est votre entrepôt -- tout y est trace
- Votre assistant IA est votre co-equipier -- posez-lui dès questions en français
- **Votre livrable :** un exécutive brief qui répond au CEO avec des données

Votre mandat : Head of Data

Vous etes seul responsable des 5 processus business

- Ventes et canaux -- revenue, performance par magasin, tendances
- Opérations et logistique -- commandes, livraisons, retours, délais
- Finance et planification -- marges, budgets, écarts, previsions
- Marketing et fidélisation -- campagnes, segments, retention
- Expérience client -- satisfaction, plaintes, comportements d'achat

Les règles du jeu

Ce qui est evalue -- et ce qui ne l'est pas

- Vous pouvez utiliser TOUS les outils que vous voulez (IA inclus)
- Mais votre travail doit être reproductible, explicable, et défendable
- Le git log est votre preuve d'iteration -- commitez souvent
- L'usage IA est trace dans ai-usage.md -- obligatoire, pas punitif
- DuckDB est le moteur analytique standard -- tout passe par la

17

On passe a l''action

Objectif : tout le monde opérationnel en 15 minutes

Acceptez votre assignment GitHub

GITHUB CLASSROOM

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

Ouvrez le lien ci-dessous dans votre navigateur. Connectez-vous a GitHub et cliquez Accept this assignment. Votre dépôt prive sera cree en quelques secondes.

`https://classroom.github.com/a/Tndi64Pu`

Ouvrez votre Codespace

Zero installation -- tout est dans le navigateur

- Sur la page de votre dépôt, cliquez Code > Codespaces > Create codespace on main
- Attendez ~2 minutes -- VS Code s'ouvre dans le navigateur
- Python, DuckDB, et les extensions sont déjà configures
- **Si vous preferez VS Code local :** suivez docs/S00-SETUP.md (Chemin B ou C)

Rencontrez votre assistant IA

Copilot, ChatGPT, Claude, Gemini -- n'importe lequel fait l'affaire ce soir

- **Si Copilot est déjà active (Student Pack verifie) :** panneau Copilot Chat dans VS Code
- **Sinon :** ouvrez ChatGPT, Claude ou Gemini dans un onglet a cote du Codespace
- **Demandez :** "Qu'est-ce qui se trouve dans mon dépôt ? Explique-moi la structure."
- **Puis :** "A quoi sert le fichier Makefile ?"
- **C'est comme ca qu'on travaille dans ce cours :** question > reponse > jugement

Le choix de l'assistant n'affecte aucun livrable -- seule la tracabilite dans ai-usage.md compte. Le pack étudiant GitHub (education.github.com/pack) donne Copilot gratuitement, mais la vérification prend 1-3 jours. Faites la demande ce soir si ce n'est pas déjà fait.

Generez vos données uniques

Chaque étudiant a un jeu de données différent

- Dans le terminal, tapez ces 3 commandes :
  - make generate
  - make load
  - make check
- Vous devriez voir PASS pour toutes les vérifications
- Si quelque chose echoue, demandez a votre assistant (Copilot/ChatGPT/Claude) de vous aider

Vos données sont derivees de votre username GitHub -- aucun token a copier.

Student Developer Pack -- a faire ce soir

Copilot gratuit pour la duree du cours (et au-dela)

- Aller sur education.github.com/pack et cliquer "Get student benefits"
- Uploader la preuve d'inscription (courriel @usherbrooke.ca ou carte étudiante)
- **Vérification typique :** 1 a 3 jours ; au pire : 2 semaines en periode de pointe
- **Une fois verifie :** activez Copilot depuis github.com/settings/copilot
- D'ici S04, Copilot devient l'outil par defaut pour les exercices de redaction

Sans Pack, vous pouvez tout faire en S01-S03 avec ChatGPT/Claude. Aucun blocage.

Votre dépôt : ce qui est donne vs ce que vous créez

DONNE (NE PAS MODIFIER)

- scripts/datagen/ -- generateur de données uniques
- src/run_pipeline.py -- orchestre le chargement
- sql/templates/ -- 6 patrons annotes a ÉTUDIER
- validation/ -- vérifications automatiques
- .devcontainer/ -- configuration Codespace

VOTRE TRAVAIL (A CRÉER ET MODIFIER)

- sql/dims/ -- vos tables de dimensions
- sql/facts/ -- vos tables de faits
- sql/views/ -- vos requêtes analytiques
- answers/ -- vos exécutive briefs
- docs/ -- vos décisions, politiques, documentation

Le pipeline : generate > load > check

Trois commandes, un cycle que vous repeterez chaque semaine

- make generate (ou .\run.ps1 generate sur Windows) -- cree vos CSVs uniques
- **make load (ou .\run.ps1 load) -- execute vos fichiers SQL dans l'ordre :** staging > dims > facts
- make check (ou .\run.ps1 check) -- verifie grain, clés, NULLs, reconciliation
- **Si check echoue :** lisez le message, corrigez votre SQL, relancez load puis check
- C'est un cycle iteratif -- pas une sequence linéaire

Detail complet dans docs/how-the-pipeline-works.md. Sous Windows, utilisez .\run.ps1 au lieu de make.

Vos ressources dans le dépôt

Tout est la -- consultez-les quand vous etes bloques

- docs/YOUR-FIRST-QUERY.md -- vos premières requêtes SQL, expliquees en français
- docs/glossary.md -- 80+ termes definis (grain, dimension, SCD, additif...)
- docs/kimball-cheatsheet.md -- aide-mémoire Kimball en une page
- docs/quick-reference.md -- les 5 commandes essentielles
- docs/faq.md + docs/TROUBLESHOOTING.md -- aide si vous etes bloques
- docs/verify-before-pushing.md -- checklist avant chaque soumission

SQLTools est aussi installe dans votre Codespace. Cliquez l'icone base de données dans la barre laterale gauche pour explorer vos tables SANS écrire de code.

Vos ressources dans le dépôt (suite)

- notebooks/explore.ipynb -- exploration optionnelle en Jupyter

Regardez vos données brutes (avant le SQL)

Ouvrez les fichiers CSV dans VS Code -- vous pouvez les VOIR

- Ouvrez data/synthetic/team_N/shared/dim_product.csv
  - → **Colonnes :** product_id, product_name, category, subcategory, brand, unit_cost, unit_price
  - → La CATEGORIE est ici -- c'est un axe d'analyse
- Ouvrez data/synthetic/team_N/shared/dim_store.csv
  - → **Colonnes :** store_id, store_name, city, region, province, store_type
  - → La REGION est ici -- l'autre axe d'analyse du CEO
- Ouvrez data/synthetic/team_N/s02/fact_sales.csv
  - → **Colonnes :** sale_line_id, order_number, order_date, customer_id, product_id, store_id, line_total
  - → Ou est la categorie ? Ou est la region ? Ce sont des IDS, pas des reponses !

Remplacez N par votre team seed (affiche par make generate).

Le probleme est visible a l'oeil nu

Les ventes contiennent des IDs -- pas des noms, pas des categories

- fact_sales a product_id (PRD-0042) mais pas "Electronics" ni "Clothing"
- fact_sales a store_id (STR-003) mais pas "Quebec" ni "Ontario"
- Pour répondre au CEO, il faut RELIER les tables entre elles
- C'est exactement le problème que le schéma en étoile résout (la semaine prochaine)
- Chargeons dans DuckDB pour tenter la jointure avec du SQL...

C'est le diagnostic fondamental du cours : les données existent, mais leur STRUCTURE empeche de répondre.

29

Exploration diagnostique

Mission : pouvez-vous répondre a la question du CEO ?

Explorez avec votre assistant

Prompts suggeres

- "Quelles tables existent dans ma base de données DuckDB ?"
- "Montre-moi les colonnes de la table raw_orders"
- "Combien de clients, de commandes, et de produits j'ai ?"
- "Ecris une requête pour voir le revenue par catégorie par région"
- "Est-ce que ces données me permettent de répondre a la question du CEO ?"

Ce que vous devriez découvrir

Le diagnostic que chaque étudiant doit poser

- Les données brutes sont des tables opérationnelles separees
- Il n'y a pas de vue consolidee "revenue par catégorie par région"
- Les jointures sont complexes et les resultats fragiles
- Il manque des hiérarchies explicites (catégorie > sous-catégorie)
- C'est exactement le problème -- et c'est ce qu'on va resoudre

Vérification rapide

Questions a reponse courte

- **Question 1 :** Pourquoi un ERP ne peut-il pas répondre directement a "ventes par catégorie par région par trimestre" ?
  - > La structure est optimisee pour les transactions, pas l'analyse
- **Question 2 :** Qu'est-ce qu'une dimension dans le contexte décisionnel ?
  - > Un axe d'analyse (qui, quoi, quand, ou)

33

Premier board brief

Le CEO attend votre reponse

Votre livrable ce soir

answers/S01_executive_brief.md

- Quelle est votre question exécutive ?
- Quels obstacles concrets avez-vous identifies dans les données ?
- Quelles mesures, dimensions et hiérarchies seront nécessaires ?
- Quelle est votre prochaine action concrete ?

Rejetez "nous avons besoin de plus de données" -- nommez QUELLE table, QUELLE colonne, QUEL grain.

Soumission et evaluation

Ce qui est attendu avant la prochaine séance

- **Fichiers requis :** answers/S01_executive_brief.md + db/nexamart.duckdb + ai-usage.md
- **Evaluation :** qualité du modèle (40%), validation (25%), justification exécutive (20%)
- Trace de processus (10%), reproductibilite (5%)
- **Commitez avant de quitter :** git add -A && git commit -m "S01 brief" && git push
- Consultez docs/verify-before-pushing.md avant de pousser
- **Deadline :** avant le debut de la séance 2

Demos boardroom

2 minutes par étudiant (3-4 au hasard)

- Quelle question posez-vous au CEO ?
- Qu'avez-vous tente de répondre avec les données brutes ?
- Quelle preuve avez-vous que la reponse est incomplète ?
- Quelle est votre prochaine décision ?

Ou en sommes-nous ?

Votre parcours en 14 séances

- **>> S01 :** OLTP vs OLAP, CEO question, exploration diagnostique [AUJOURD'HUI]
  - **S02 :** Schema en étoile, grain, dimensions conformes
  - **S03 :** Slowly Changing Dimensions (SCD)
  - **S04 :** Dimensions degenerees, junk dims, analyse de panier
  - **S05 :** Examen intra 1 (S01-S04)
  - **S06-S09 :** Integration multi-star, dimensions spéciales, ponts, types de faits
  - **S10 :** Examen intra 2 (S06-S09)
  - **S11-S13 :** Documentation, défense, au-dela du modèle
  - **S14 :** Examen final

Vérification mi-séance

PROFOS

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

Pourquoi un ERP ne peut-il pas répondre directement à 'ventes par catégorie par région par trimestre' ?

https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GIS805-01/poll/mid-check

A retenir de ce soir

1. OLTP enregistre des transactions. OLAP répond a dès questions stratégiques.
2. Mesure + Dimension + Hiérarchie + Grain = le vocabulaire du cours.
3. NexaMart est votre entreprise. Le CEO attend un brief chaque semaine.
4. Votre assistant IA est votre co-equipier. Utilisez-le des maintenant.
5. La semaine prochaine : le schema en étoile -- la solution au problème de ce soir.

Exit ticket

PROFOS

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

Quelle est LA question exécutive que vous avez identifiee pour NexaMart, et quel obstacle principal empechait d'y répondre ce soir ?

https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GIS805-01/poll/exit