UNIVERSITÉ DE SHERBROOKE · ÉCOLE DE GESTION

GIS805

Session 02 / 14

Schéma en étoile, grain et dimensions conformes : le premier modèle NexaMart

Structuration et analyse multidimensionnelle

C

PROFESSEUR

Prof. Carlos Denner dos Santos

Département des systèmes d'information et méthodes quantit...

DATE

14 mai 2026

LIEU

Longueuil

HORAIRE

19 h 00 – 22 h 00

Votre séance, en bref

Voici comment se déroule votre soirée — 3 temps forts.

- 25 min — **Grain : la décision irréversible**
- 40 min — **Sprint 1 : schema v1**
- 40 min — **Sprint 2 : première réponse SQL**

Quel schema en étoile rend votre question CEO repetable et fiable chaque mois ?

— Le CEO de NexaMart Group, séance 2

Rappel S01 : le problème diagnostique

Vos données brutes ne répondent pas a la question du CEO

- La semaine derniere, vous avez explore les données opérationnelles
- Aucun étudiant n'a pu répondre avec les tables brutes
- **Aujourd'hui :** on construit la structure qui rend la reponse repetable
- **L'outil :** le schema en étoile de Ralph Kimball

01

Le grain : la décision la plus importante

Une fois choisi, le grain ne change plus sans reconstruire

Qu'est-ce que le grain ?

Le contrat fondamental de votre table de faits

- Le grain definit ce que represente exactement UNE ligne dans la table de faits
- **Exemple :** "une ligne = une ligne de commande (order line item)"
- **Ou :** "une ligne = un événement de vente au point de caisse"
- **Pensez-y comme un tableur :** chaque rangee de votre Excel represente quoi exactement ?
- Le grain determine quelles questions sont possibles -- et lesquelles sont fermees
- Un grain trop grossier ferme dès questions pour toujours

Bon grain vs mauvais grain

GRAIN FIN : UNE LIGNE DE COMMANDE

- Permet : ventes par produit par jour
- Permet : panier moyen par client
- Permet : retour par SKU
- Cout : plus de lignes, plus d'espace

GRAIN GROSSIER : UN EN-TETE DE COMMANDE

- Perd : detail par produit
- Perd : analyse par SKU
- Perd : panier par catégorie
- "Combien de X par produit ?" → impossible

Le grain statement

Une phrase qui engage toute la conception

- "Une ligne dans fact_sales represente une ligne de commande unique"
- "Une ligne dans fact_inventory_snapshot represente l'état d'un produit dans un magasin a une date donnée"
- Ce statement est un contrat -- il guide le choix des dimensions et des mesures
- Si deux personnes le lisent differemment, le grain n'est pas clair

Additivite : pourquoi le grain compte pour les calculs

Toutes les mesures ne s'additionnent pas de la même façon

- **ADDITIVE :** revenue, quantite -- s'additionnent sur toutes les dimensions
- **SEMI-ADDITIVE :** solde de compte, stock -- s'additionnent sur certaines dimensions, pas le temps
- **NON-ADDITIVE :** ratio, pourcentage, prix unitaire -- ne s'additionnent jamais
- Un grain mixte (en-tete + lignes) melange les types → erreurs d'agrégation

02

Le schema en étoile

La structure qui rend les questions repetables

Anatomie d'un schema en étoile

Une table de faits au centre, des dimensions autour

- **TABLE DE FAITS :** les mesures (revenue, quantite, cout)
- **DIMENSION :** les axes d'analyse (produit, client, date, magasin)
- **FOREIGN KEYS :** chaque fait pointe vers ses dimensions via des clés
- Pas de jointures entre dimensions -- tout passe par la table de faits
- **Resultat :** une requête simple répond a la question du CEO

L'étoile NexaMart : fact_sales

Le premier modèle de votre entrepôt

- **fact_sales :** order_key, product_key, customer_key, store_key, date_key
- **Mesures :** revenue, quantity, discount_amount, cost
- **dim_product :** product_key, name, category, subcategory, brand
- **dim_customer :** customer_key, name, segment, city, région
- **dim_date :** date_key, date, month, quarter, year
- **dim_store :** store_key, name, city, région, province

Dimensions conformes

Le secret de l'integration entre tables de faits

- Une dimension conforme est partagee identiquement entre plusieurs tables de faits
- dim_date est conforme si fact_sales et fact_returns utilisent la même table
- dim_product est conforme si toutes vos tables de faits partagent les mêmes catégories
- Sans dimensions conformes, chaque étoile est isolée -- pas de comparaison possible
- En S06, on utilisera ces dimensions pour le drill-across

Conforme vs non conforme

CONFORME

- dim_date identique partout
- dim_product mêmes catégories
- Permet : "ventes vs retours par produit"
- Prerequis pour le drill-across (S06)

NON CONFORME

- Sales dit "Electronics", Returns dit "Electronique"
- Sales a 12 mois, Returns a 52 semaines
- Impossible de comparer entre tables
- Chaque étoile est isolée

Votre copilote cette semaine

Comment travailler avec votre assistant IA pour le schema en étoile

✓ PROMPTS QUI MARCHENT

- Voici mon grain statement : [grain]. Est-ce coherent avec mes dimensions ?
- Genere le DDL DuckDB pour fact_sales avec ce grain.
- Ecris une requête qui joint fact_sales a 3 dimensions.

✕ PROMPTS À REJETER

- l'assistant propose un grain mixte (en-tete + lignes dans la même table)
- l'assistant snowflake vos dimensions ou utilise des clés naturelles

Votre copilote cette semaine (suite)

- **Règle d'or :** si le SQL genere contient un mot que vous ne comprenez pas, demandez "Explique chaque ligne"

03

Sprint 1 : votre première étoile

Grain statement + schema Mermaid + chargement DuckDB

Ce que vous devez produire

Sprint 1 (40 min) : grain + Mermaid + DDL des dimensions

- 1. Grain statement dans answers/S02_executive_brief.md — avant toute ligne de SQL
- 2. Diagramme Mermaid du schema en etoile dans le brief
- **3. Cinq fichiers DDL dans sql/dims/ :** dim_product, dim_customer, dim_store, dim_date, dim_channel
- 4. Chaque fichier lit depuis raw_dim_* et cree une table dim_* avec cle subrogee (ROW_NUMBER)
- 5. make load — verifiez que toutes les dims s'affichent OK sans erreur

ℹ Modele dans sql/templates/01_dim_from_raw.sql. Une fois les dims creees, vous ne touchez plus aux raw_* pour vos analyses.

Générer le diagramme Mermaid avec votre assistant IA

Copiez ce prompt dans GitHub Copilot Chat

- Prompt à copier-coller :
  - "Génère un diagramme Mermaid `erDiagram` pour mon étoile NexaMart.
  - Au centre : `FACT_SALES` au grain « une ligne de commande ».
  - Inclus : `DIM_PRODUCT`, `DIM_CUSTOMER`, `DIM_DATE`, `DIM_STORE`, `DIM_PROMO`.
  - Montre les clés étrangères avec ||--o{ et les noms de relation.
  - Syntaxe DuckDB. Pas de snowflake. Pas de clés naturelles dans les faits."
- Insérez le bloc généré directement dans answers/S02_executive_brief.md
- **Vérifiez :** chaque dimension a une clé _key ? fact_sales a au moins 5 foreign keys ?

ℹ Le diagramme est dans le brief -- pas dans un fichier séparé. Voir docs/s02-sample-brief.md pour un exemple complet.

Erreurs frequentes a eviter

Ce que votre instructeur va vérifier

- **Grain mixte :** unit_price ET total_sales dans la même table de faits
- **Dimension dans les faits :** mettre le nom du produit directement dans fact_sales
- **Pas de grain statement :** "on verra plus tard" n'est pas une stratégie
- **Trop de dimensions :** chaque dimension doit répondre a un besoin analytique réel

04

Sprint 2 : la première reponse SQL

Prouvez que votre modèle répond a la question du CEO

Le critere d'acceptation

Sprint 2 (40 min) : fact_sales DDL + requete CEO

- 1. sql/facts/fact_sales.sql — DDL depuis raw_fact_sales, commentaire grain en tete
- 2. make load — fact_sales se cree apres les dims (staging → dims → facts)
- 3. sql/analysis/s02-ceo-answer.sql — revenus par categorie x region x trimestre
- **4. Testez la jointure :** fact_sales JOIN dim_product JOIN dim_store JOIN dim_date
- 5. make check — les 4 regles S02 doivent etre PASS
- 6. Collez le resultat SQL dans le brief, section Preuve

Modele dans sql/templates/02_fact_with_grain.sql. Jamais de raw_* dans les requetes analytiques.

Lire le SQL comme une phrase française

Traduire SQL en langage naturel -- et inversement

- "Revenue par catégorie par région par trimestre" en français devient :
  - SELECT p.category, s.région, d.quarter, SUM(f.revenue) AS revenu
  - FROM fact_sales f JOIN dim_product p ... JOIN dim_store s ... JOIN dim_date d ...
  - GROUP BY p.category, s.région, d.quarter
- Chaque mot après "par" = une colonne dans GROUP BY
- Le mot "total" ou "combien" = une fonction SUM() ou COUNT()
- **Astuce :** ecrivez TOUJOURS la question en français avant d'écrire le SQL

Voir docs/YOUR-FIRST-QUERY.md pour un guide complet étape par étape.

Validation : make check après chaque changement

Le pipeline vous dit si votre étoile est solide

- **Après avoir charge vos tables :** make check (ou .\run.ps1 check)
- **PASS grain_check :** votre grain est respecte (pas de doublons)
- **PASS fk_not_null :** toutes vos clés etrangeres pointent vers des dimensions existantes
- FAIL = un problème dans votre SQL. Lisez le message, corrigez, rechargez
- **Demandez a votre assistant :** "Voici l'erreur de make check : [message]. Que dois-je corriger ?"
- Ne soumettez pas avant que make check passe -- c'est votre filet de securite

Board brief S02

Votre livrable exécutif

- **Question :** "Quel schema en étoile rend votre question CEO repetable ?"
- **Reponse :** grain statement + schema + première requête fonctionnelle
- **Evidence :** le resultat SQL qui montre revenue par catégorie x région x trimestre
- **Décision :** quel grain avez-vous choisi et pourquoi ?

Soumission et evaluation

Ce qui est attendu avant S03

- **Brief :** answers/S02_executive_brief.md (grain + Mermaid + preuve SQL collee)
- **Dims :** sql/dims/dim_product, dim_customer, dim_store, dim_date, dim_channel
- **Fait :** sql/facts/fact_sales.sql (commentaire grain en tete)
- **Requete :** sql/analysis/s02-ceo-answer.sql
- **Evaluation :** modele (40%), validation SQL (25%), justification executive (20%)
- Trace de processus (10%), reproductibilite (5%)

Soumission et evaluation (suite)

- **Commitez :** git add -A && git commit -m "S02 star schema v1" && git push

Ou en sommes-nous ?

Votre parcours en 14 séances

- S01 : OLTP vs OLAP, CEO question [FAIT]
- **>> S02 :** Schema en étoile, grain, dimensions conformes [AUJOURD'HUI]
- S03 : Slowly Changing Dimensions (SCD)
- S04 : Dims degenerees, junk dims, panier
- S05 : Examen intra 1 (S01-S04)
- S06-S09 : Integration, dimensions spéciales, ponts, types de faits
- S10-S14 : Examen intra 2, documentation, défense, final

Vérification mi-séance

PROFOS

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

Que signifie 'le grain' d'une table de faits ?

https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GIS805-02/poll/mid-check

A retenir de ce soir

1. Le grain est un contrat : une ligne dans fact_sales represente exactement...
2. Le schema en étoile = une table de faits + des dimensions autour.
3. Les dimensions conformes rendent le drill-across possible (on y arrive en S06).
4. Un modèle n'est valide que s'il produit une reponse SQL verifiable.
5. La semaine prochaine : que se passe-t-il quand les dimensions changent ? (SCD)

Exit ticket

PROFOS

Sortez votre téléphone, scannez, répondez en moins de 30 secondes.

Qu'est-ce que le CEO peut décider maintenant que votre modèle S02 est livré ?

https://profos-dhowwtjefa-nn.a.run.app/exit-ticket/GIS805-02/poll/exit